



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ЛАБОРАТОРНАЯ РАБОТА № 1

по дисциплине «Машинное обучение»
на тему «Библиотеки Python для машинного обучения. Работа с данными»

Выполнил:

Студент Войстрик А.А.

Группа ИПБП41

Проверил:

Дольников Максим Геннадьевич

Ростов-на-Дону

2026 г.

1. Цель работы

Изучить основные библиотеки Python для машинного обучения (NumPy, Pandas, Matplotlib, SciPy, scikit-learn, TensorFlow, Keras, PyTorch) и приобрести практические навыки работы с табличными данными: чтение и запись, предобработка, статистический анализ, тензорные вычисления, обработка изображений.

2. Задачи

1. Освоить чтение и запись данных в различных форматах (CSV, TXT, XLSX, MAT).
2. Научиться выявлять и обрабатывать проблемы в данных (пропуски, нечисловые значения).
3. Реализовать собственные функции масштабирования (MinMax, Standard) и сравнить их со scikit-learn.
4. Освоить статистический анализ данных средствами NumPy, Pandas, SciPy.
5. Научиться работать с тензорами TensorFlow, PyTorch и Keras.
6. Освоить базовую обработку изображений средствами SciPy и scikit-image.

3. Описание структуры проекта

Код организован модульно:

Модуль	Назначение
main.py	Точка входа, последовательный запуск всех заданий 1–50
src/config.py	Фиксация seed, пути data/ и output/
src/io_utils.py	Чтение и запись таблиц, сохранение графиков
src/data_loader.py	Проверка качества данных, вывод таблицы, извлечение столбцов
src/preprocess.py	Обработка пропусков, преобразование в NumPy, разбиение выборки
src/scaling.py	Кастомные MinMaxScalerCustom и StandardScalerCustom
src/stats_analysis.py	Статистики, доверительные интервалы, корреляции, спектральный анализ
src/windows.py	Скользящее окно и скользящее среднее
src/tensors.py	Операции с тензорами TensorFlow, PyTorch и Keras
src/matrix_ops.py	Разреженные матрицы, обращение, PCA-пайплайн
src/image_proc.py	Задание 50 — десять операций обработки изображения

Все промежуточные результаты (графики, экспорт таблиц) сохраняются в каталог output/ с меткой времени.

4. Ход выполнения работы

Полный вывод выполнения всех заданий 1–50 представлен на двух скриншотах консоли.

```
=== ЛАБОРАТОРНАЯ РАБОТА №1. ВЫПОЛНЕНИЕ ПАЙПЛАЙНА ===

[Задание 1] Датасет загружен. Строк: 500, Столбцов: 7
[Задание 2] Данные сохранены в 4 формата: ['xlsx', 'csv', 'txt', 'mat']
[Задание 4] Отчет качества: пропусков по колонкам -> {'id': 0, 'timestamp': 0, 'category': 0, 'x1': 0, 'x2': 10, 'x3': 0, 'y': 0}

[Задание 5] Первые строки датасета:
   id  timestamp  category  x1  x2  x3  y
0  1  2024-01-01 00:00:00    A  0.17517845559778916 -1.254599 -0.809604  0.979416
1  2  2024-01-01 01:00:00    A  0.2022088913599509  4.507143  0.425061 -5.105829
2  3  2024-01-01 02:00:00    B  0.7691980363788655  2.319939 -0.469839 -0.743650

Shape: (500, 7)
Dtypes:
id          int64
timestamp   str
category    str
x1          str
x2         float64
x3         float64
y          float64
dtype: object

[Задание 8] Очистка и предобработка данных...
[Задание 9] Сформирован массив NumPy X: shape = (500, 4), dtype = float64
[Задания 10-11] MinMaxScalerCustom и StandardScalerCustom протестированы с инверсией.
[Задание 12] Выборки сформированы: Train=(350, 4), Val=(75, 4), Test=(75, 4)

[Задания 14-17] Построение графиков распределения...
[Задание 18] Статистика x1: mean=0.0217, var=0.7014, median=0.0217
[Задание 19] ДИ 95% для среднего: (-0.0519, 0.0954); для дисперсии: (0.6232, 0.7989)
[Задания 20-22] Корреляция Пирсона (x1, x2): r=0.0168 (p=7.0776e-01)
[Задания 23-26] Норма L1=374.03, Норма L2=18.73, Скалярное произведение=20.66
[Задание 27] Гипотезы: Uniform KS p=0.0000, Norm Shapiro p=0.0000
[Задание 34] Кастомный MinMaxScaler совпадает со scikit-learn (atol=1e-10).
```

(загрузка данных, предобработка, статистики, корреляции, проверка скейлеров)

```
[Задание 34] Кастомный MinMaxScaler совпадает со scikit-learn (atol=1e-10).
[Задание 35] Инверсия масштабирования успешно восстановила x.
[Задания 36-37] Матрица скользящих окон: (496, 5), точек скользящего среднего: 496

[Задания 38-45] Тензорные вычисления...
TF результат: (5, 4), PyTorch результат: torch.Size([5, 4])
Эквивалентность Keras Ops и PyTorch: True

[Задания 46-49] Матричные операции и PCA...
Разреженная матрица CSR (NNZ): 100000
Проверка обратной матрицы: True
Форма 3D-тензора F: (500, 4, 3)
PCA log-likelihood по скейлерам: {'minmax': 19824.06153313555, 'std': 12313.231308981385}
Наилучший масштабировщик: minmax

=== Все задания (1-49) выполнены успешно! ===
Задание 50:
[Задание 50] Все 10 операций обработки изображения выполнены и сохранены в output/.
```

(тензорные вычисления, матричные операции, PCA, обработка изображения)

4.1. Раздел 1. Считывание, запись и проверка данных (задания 1–7)

Загружен датасет dataset_var4.csv (500 строк, 7 столбцов).

Данные сохранены в 4 формата: xlsx, csv, txt, mat.

Отчёт качества показал 10 пропусков в столбце x2.

Выведены первые строки таблицы, размерность и типы данных.
Извлечены столбцы варианта: x1, x2, x3, y.

(см. Рисунок 1)

4.2. Раздел 2. Предобработка данных (задания 8–13)

Выполнена очистка данных (приведение нечисловых значений и заполнение средним).
Сформирован массив NumPy X формы (500, 4), dtype = float64.
Кастомные MinMaxScalerCustom и StandardScalerCustom протестированы с инверсией — данные успешно восстанавливаются.
Выборка разбита на Train (350, 4), Val (75, 4), Test (75, 4).



(см. Рисунок 1)


4.3. Раздел 3. Работа с данными и сигналы (задания 14–37)

Построены графики распределений.
Статистика столбца x1: mean = 0.0217, var = 0.7014, median = 0.0217.
95% доверительный интервал для среднего: (−0.0519, 0.0954); для дисперсии: (0.6232, 0.7989).
Корреляция Пирсона (x1, x2): $r = 0.0168$ ($p = 0.707$).
Нормы: $L1 = 374.03$, $L2 = 18.73$; скалярное произведение = 20.66.
Гипотезы: Uniform KS $p = 0.0000$, Norm Shapiro $p = 0.0000$.
Кастомный MinMaxScaler совпадает со scikit-learn (atol = 1e-10).
Инверсия масштабирования успешно восстановила исходные данные.
Матрица скользящих окон: (496, 5), точек скользящего среднего: 496.



(график исходных признаков)






(спектрограмма)



(периодограмма)



(численные результаты — на Рисунках 1 и 2)


4.4. Разделы 4–5. Тензоры и матричные операции (задания 38–49)

Тензорные вычисления:

- TensorFlow результат: (5, 4)
- PyTorch результат: `torch.Size([5, 4])`
- Эквивалентность Keras Ops и PyTorch: True

Матричные операции и PCA:

- Разреженная матрица CSR (NNZ): 100000
- Проверка обратной матрицы: True
- Форма 3D-тензора F: (500, 4, 3)
- PCA log-likelihood: minmax = 19824.06, std = 12313.23
- Наилучший масштабировщик: minmax



(кумулятивная объяснённая дисперсия PCA)

(см. Рисунок 2)

4.5. Задание 50. Обработка изображения

Все 10 операций обработки изображения выполнены и сохранены в output/.



(RGB-каналы)

Исходное



Поворот на 40.0°




(поворот на 40°)

Исходное




Ч/б



(оттенки серого)

Гистограмма ч/б изображения



(гистограмма яркостей)

Тёмные (≤ 57.7734375)



Средние ($57.7734375 - 86.66015625$)



Светлые (> 86.66015625)



(разбиение на тёмные / средние / светлые)

Исходное



Круговая рамка



(круговая рамка)

Исходное



Шум ($\sigma=25.0$)




(шум, $\sigma = 25$)

Исходное



Размытие (sigma=2.0)



(размытие, сигма = 2)

Исходное



Sharpening



(повышение резкости)

Исходное



РСА (3 компонент)



(РСА и восстановление)

(см. Рисунок 2 — сообщение о успешном выполнении задания 50)

5. Результаты

Все 50 заданий выполнены успешно.

Основные результаты:

- Данные корректно читаются и записываются в 4 формата.
- Пропуски и нечисловые значения обработаны.
- Кастомные скейлеры полностью совпадают со scikit-learn (проверка allclose с допуском $1e-10$).
- Получены статистики, доверительные интервалы, корреляции, спектральные характеристики.
- Тензорные операции в TensorFlow, PyTorch и Keras дают согласованные результаты.
- Реализованы разреженные матрицы, обращение, трёхмерный тензор и РСА-пайплайн.
- Выполнены все 10 операций обработки изображения; результаты сохранены в output/.

Полный исходный код и все сгенерированные файлы доступны в репозитории:

https://github.com/Absult56/ML_lab1

6. Выводы

В ходе лабораторной работы освоены ключевые библиотеки Python для машинного обучения.

Приобретены практические навыки:

- работы с табличными данными (чтение, запись, очистка, масштабирование);
- статистического и спектрального анализа;
- тензорных вычислений в трёх фреймворках;
- базовой обработки изображений.

Реализованные кастомные классы масштабирования показали полную эквивалентность стандартным реализациям `scikit-learn`. Модульная структура проекта позволяет легко расширять функциональность и повторно использовать отдельные компоненты.